

AI-Ready Context

watsonx 위에 올린 설명가능한 Agentic RAG + Knowledge Graph

질문마다 벡터 · 그래프 · SQL 도구로 자동 라우팅하고
답의 근거를 그대로 보여주는 데모

Kiyeon Jeon · AI Engineer, IBM Client Engineering Korea
IBM TechXchange Korea 워크숍

목차

1. 배경 — 왜 Agentic RAG + Knowledge Graph인가
2. 아키텍처 & 데이터 — 스토어 구성 · 동작 방식 · 문서 적재 · 데모 코퍼스
3. 데모 — ① 3경로 라우팅(vector/graph/sql) · ② No-code 즉석 적재 · ③ 설명가능성
4. 고도화 — 각 도구를 한 단계 더 (text-to-SQL · KG · 혼합문서 · Langflow)
5. 심화 — KG를 그래프DB가 아닌 NoSQL(AstraDB)에 담은 법
6. 운영 — 검색·KG 품질 개선 · 배포 · 보안 · 한계
7. 정리 & Q&A

왜 이걸 만들었나

- RAG의 한계 — 벡터 검색 하나로는 못 푸는 질문이 많다
 - "총 몇 개 문서가 있나?" → 검색이 아니라 집계(SQL)
 - "A 법과 B 기관의 관계는?" → 의미 유사도가 아니라 관계(그래프)
- 신뢰 문제 — LLM 답이 맞는지 어떻게 믿나? → 근거(grounding)를 보여줘야 한다
- 운영 현실 — 폐쇄망/규제 산업은 SaaS LLM을 그냥 못 쓴다 → watsonx로 거버넌스


→ "질문에 맞는 도구를 고르고, 근거를 보여주는" 에이전틱 RAG

무엇을 보여주나 (3가지 포인트)

1. 에이전트 라우팅 — Langflow의 watsonx granite 에이전트가 `vector / graph / sql` 도구를 tool-calling으로 선택
→ 어떤 도구를 썼는지 **tool-trace** 배지로 표시
2. 설명가능성(Explainability) — 답변마다 인용 + 근거 패널
→ 검색된 청크 · KG 서브그래프 · SQL 결과를 펼쳐서 확인
3. No-code 즉석 적재 — UI에서 문서를 텍스트/URL/PDF로 추가
→ 답이 즉시 바뀌고, 삭제하면 원복
→ "grounding 있으면 정확, 없으면 환각"을 클릭만으로 시연

아키텍처 (High-Level)

Agentic RAG + Knowledge Graph — High-Level



구성요소 (스택)

역할	구성요소
Chat UI	<code>rag-ui</code> — FastAPI (OpenShift) · tool-trace·근거 패널
오케스트레이션	Langflow 에이전트 (IBM open source, tool-calling) · 파이썬 폴백
벡터 검색	OpenSearch (IBM watsonx.data) — kNN + BM25 하이브리드
지식그래프	DataStax AstraDB (IBM watsonx.data) — 엔티티(+emb)/엣지
text-to-SQL	IBM watsonx.data Iceberg + Presto — AML 데이터셋
임베딩 + LLM	IBM watsonx.ai granite
문서 파싱	Docling (IBM open source)

데이터 스토어 — 한 질문, 세 가지 검색

스토어	무엇을 담나	어떤 질문에 강한가
OpenSearch	청크 + 임베딩(768d) + 원문 텍스트	"가명정보란 무엇인가" (의미 검색)
AstraDB (KG)	엔티티(임베딩) · 관계(엣지)	"접근매체와 감독기관의 관계" (관계)
Iceberg / Presto	AML 비즈니스 데이터셋	"위험등급 high 고객의 거래 총액" (text-to-SQL)

- 핵심: 같은 문서를 세 가지 형태로 저장해 두고, 질문에 맞춰 골라 읽는다
- 세 스토어 모두 **IBM watsonx.data** 패밀리 (OpenSearch · Iceberg/Presto · DataStax AstraDB)
- OpenSearch는 벡터(의미) + BM25(정확 매칭)를 **RRF로 융합** → 약어·법령명에 강함

동작 방식 — 질문이 들어오면

질문

- [라우터] granite가 도구 선택 {vector, graph, sql} (+관계형 키워드 백스톱)
- vector : OpenSearch 하이브리드 (kNN + BM25, RRF 융합, k=8)
- graph : AstraDB KG — 엔티티 임베딩 시드 → 1홉 이웃 조회 → 별칭 병합
- sql : text-to-SQL — granite가 Presto SELECT 생성 → 가드 → 실행 (AML 데이터)
- [합성] granite가 컨텍스트로 답변 생성 + 인용
- UI : 답변 + tool-trace 배지 + 근거 패널 (생성 SQL 포함)

- 챗 UI(/api/chat)는 오케스트레이션을 **Langflow 에이전트**에 위임(watsonx granite, tool-calling)
 - 오류 시 **in-process** 파이썬 에이전트로 폴백(무대 안전망)
- 라우팅.검색.합성.임베딩은 전부 **watsonx.ai granite**, 답변 언어는 질문 언어를 따름(한글→한글)

문서 적재 — 한 번에 4개 저장소

```
ingest_source(문서)    doc_id = sha1(source)
├─ OpenSearch          : 청크 + granite 임베딩(768d)    ← vector
├─ AstraDB kg          : granite 추출 엔티티(+emb)/엣지  ← graph
├─ AstraDB doc_registry: 제목·소스·해시·카운트          ← 추적/증분
└─ Iceberg corpus      : 문서 인벤토리 1행              ← sql
```

- 멍등 upsert (doc_id 기준) + **content-hash** 스킵 → 재적재해도 중복 없음
- CronJob **rag-reindex** (30분): 등록된 소스 재적재, 바뀐 것만 재처리
- 문서 파싱은 **docling-serve** (텍스트 / URL / PDF·DOCX → markdown)

데모 코퍼스 — 한글 금융·컴플라이언스

한글 금융 법령 + 영문 README — md · PDF · URL 세 입력 경로가 모두 섞인 혼합 코퍼스

- **md (4)** — 개인정보 보호법 · 마이데이터 · 전자금융거래법 · 전자금융감독규정
 - **PDF (2)** — 신용정보법 · 특정금융정보법 (*docling 변환 적재*)
 - **URL (2)** — Docling README · Langflow README (*docling fetch*)
-
- 왜 금융 법령? 법령 간 교차참조가 많아 지식그래프가 "의미를 갖는" 도메인
 - md/PDF/URL 혼합 → 문서 처리 다양성 + 한글/영문 다국어 동시 시연
 - 별도 AML 비즈니스 데이터셋(iceberg_data.aml)으로 text-to-SQL 시연

데모 1 — 세 가지 검색 경로

경로	예시 질문	보여줄 것
vector	"가명정보란 무엇이고 동의 없이 쓸 수 있는 목적은?"	인용칩 + 검색 청크(유사도 바)
graph	"접근매체와 감독기관의 관계를 지식그래프로 보여줘"	엔티티 칩 + 엣지 트리플
sql	"위험등급 high 고객의 플래그 거래 총액을 상대국가별로?"	생성 SQL 코드블록 + 결과 표
hybrid	"자금세탁 의심거래는 어디 보고하고, VASP 의무는?"	vector+graph 배지 동시 점 등

→ 각 답변에서 **tool-trace** 배지와 근거 패널을 펼쳐 보여준다

데모 1a — vector 경로

 Lakehouse Assistant
Agentic RAG · Knowledge Graph · watsonx

OpenSearchAstraDBwatsonx.datawatsonx.ai

☰ 코퍼스

가명정보란 무엇이고 동의 없이 쓸 수 있는 목적은?

가명정보란 추가 정보 없이는 특정 개인을 알아볼 수 없도록 가명처리한 정보이다. 가명정보는 통계작성, 과학적 연구, 공익적 기록보존 목적으로 정보주체의 동의 없이 처리할 수 있다. 가명정보 개념은 신용정보법의 가명정보·익명정보 체계와 연계되어 마이데이터·데이터 결합에 활용된다.

개인정보 보호법 #1개인정보 보호법 #0신용정보법 #0마이데이터 (본인신용정보관리업) #0전자금융감독규정 #0신용정보법 #1특정금융정보법 (자금세탁방지) #0특정금융정보법 (자금세탁방지) #1

TOOLS● vector search● knowledge graph● sql / iceberg

● Retrieved passages 8

개인정보 보호법 #1 문서 0.033

없이는 특정 개인을 알아볼 수 없도록 가명처리한 정보이다. 가명정보는 통계작성, 과학적 연구, 공익적 기록보존 목적으로 정보주체의 동의 없이 처리할 수 있다. 가명정보 개념은 **신용정보법**의 가명정보·익명정보 체계와 연계되어 마이데이터·데이터 결합에 활용된다. ## 정보주체의 권리 정보주체는 자신의 개인정보에 대하여 열람, 정정·삭제, 처리정지, 전송요구(개인정보 이동권)를 요구할 권리를 가진다. 전송요구권은 **마이데이터** 서비스의 법적 기반 중 하나이다. > 관련 문서: 신용정보법, 마이데이터(본인신용정보관리업), 전자금융거래법, 특정금융정보법

개인정보 보호법 #0 문서 0.033

개인정보 보호법 (PIPA) 핵심 정리 ## 목적과 적용 대상 개인정보 보호법은 개인정보의 처리 및 보호에 관한 사항을 정하여 개인의 자유와 권리를 보호하는 것을 목적으로 한다. 살아 있는 개인에 관한 정보로서 성명·주민등록번호 등으로 특정 개인을 알아볼 수 있는 정보를 **개인정보**라 한다. 개인정보 파일을 운용하기 위하여 개인정보를 처리하는 자를 **개인정보처리자**라 하고, 처리의 대상이 되는 사람을 **정보주체**라 한다. ## 감독기구 이 법의 소관 감독기구는 **개인정보보호위원회(개인정보위)**이다. 개인정보보호위원회는 정책 수립, 침해 조사, 과징금·과태료 부과를 담당한다. 금융 분야의 개인정보는 **신용정보법**이 우선 적용되며, 그 감독은 **금융위원회**와 **금융감독원**이 수행한다. ## 핵심 의무 - **수집·이용 동의**: 개인정보처리자는 정보주체의 동의를 받아 개인정보를 수집·이용한다. 목적 외 이용은 원칙적으로 금지된다. - **유출 통지·신고**: 개인정보가 유출되었을 때 개인정보처리자는 정보주체에게 지체 없이 통지하고, 일정 규모 이상은 **72시간** 이내에 개인정보보호위

데모 1b — graph 경로

 Lakehouse Assistant
Agentic RAG · Knowledge Graph · watsonx

OpenSearchAstraDBwatsonx.datawatsonx.ai

☰ 코퍼스

전자금융거래법의 접근매체와 감독기관의 관계는?

전자금융거래법은 접근매체를 통해 전자금융거래를 수행하며, 이를 감독하는 기관은 금융위원회이며, 검사는 금융감독원이 수행한다. 또한, 전자지급거래의 청산·결제에 대해서는 한국은행이 감시(oversight) 기능을 수행한다.

관련 문서: 전자금융거래법#0

전자금융거래법#0전자금융감독규정#0특정금융정보법 (자금세탁방지) #0마이데이터 (본인신용정보관리업) #0마이데이터 (본인신용정보관리업) #1특정금융정보법 (자금세탁방지) #1전자금융거래법#1전자금융감독규정#1

TOOLS

vector searchknowledge graphsql / iceberg

Retrieved passages 8

Knowledge subgraph 32

마이데이터 service접근매체 medium전자금융감독규정 regulation전자금융거래법 law전자금융거래 transaction

금융회사 entity금융감독원 organization개인정보 보호법 law전자금융업자 entity

이상거래담지시스템 FDS (technology5·5·7 guideline접근통제·계정관리 technology

정보보호최고책임자 CISO (role고객원금거래보고 CTR (procedure금융보안원 regulatory_body

금융위원회 organization

마이데이터 — related_to → 접근매체

전자금융감독규정 — based_on → 전자금융거래법

데모 1c — sql 경로 (text-to-SQL)

 Lakehouse Assistant
Agentic RAG · Knowledge Graph · watsonx

OpenSearchAstraDBwatsonx.datawatsonx.ai

☰ 코퍼스

인덱싱된 문서는 총 몇 개이고 각각 체크 수는?

인덱싱된 문서는 총 8개이고, 각각의 체크 수는 다음과 같습니다:

- Docling README: 9개
- Langflow README: 6개
- 마이데이터(본인신용정보관리업): 2개
- 신용정보법: 2개
- 전자금융거래법: 2개
- 개인정보 보호법: 2개
- 특정금융정보법(자금세탁방지): 2개
- 전자금융감독규정: 2개

TOOLS

- * vector search
- * knowledge graph
- * sql / iceberg

• Corpus / SQL rows 8

Docling README	https://raw.githubusercontent.com/docling-project/docling/main/README.md	9	14	14
Langflow README	https://raw.githubusercontent.com/langflow-ai/langflow/main/README.md	6	15	15
마이데이터(본인신용정보관리업)	/corpus/03_mydata.md	2	11	9
신용정보법	/corpus/02_credit.md	2	11	12
전자금융거래법	/corpus/04_efta.md	2	11	10
개인정보 보호법	/corpus/01_pipa.md	2	12	10
특정금융정보법(자금세탁방				

Ask the lakehouse...

➤


데모 2 ★ — No-code 즉석 적재 (하이라이트)

RAG의 본질을 UI 클릭만으로 시연

1. 적재 전 질문 — "클라우드 보안인증(CSAP)는 어느 기관이 평가하나?"
→ ❌ 환각 (코퍼스에 없어 엉뚱한 답/가짜 인용)
2. ⚙️ 코퍼스 드로어 → 텍스트 탭 → 제목+본문 붙여넣기 → 추가 적재
→ "적재 완료" 토스트, 목록 8 → 9
3. 같은 질문 재질의 → ✅ 정확 + 새 문서 인용
4. 🗑️ 삭제 → 같은 질문 → 다시 환각으로 원복

입력 3종: 텍스트(주력) · URL(docling fetch) · 파일(PDF/DOCX)

데모 2 — 코퍼스 관리 드로어



설명가능성 — 근거를 어떻게 보여주나

- **tool-trace** 배지 — 이 답에 vector / graph / sql 중 무엇을 썼는지
- 인용 칩 — 답변 속 주장 ↔ 출처 문서 연결
- 근거 패널 (펼치기)
 - Retrieved passages — 청크별 유사도 바
 - Knowledge subgraph — 엔티티 + 엣지 트리플
 - Corpus / SQL rows — Iceberg 테이블
- 출처 링크 — URL 문서는 원문, 직접작성 md는 `/corpus/*.md` 서빙으로 열림

고도화 — 각 도구를 한 단계 더

"모양만 에이전틱"에서 각 도구에 실제 깊이를 — 설명가능성 UI와 무대 안정성은 그대로

도구	Before (얕음)	After (이번 고도화)
SQL	corpus 메타데이터 고정 쿼리	text-to-SQL — AML 데이터셋에 granite가 SELECT 생성·실행 (SELECT-only 가드 + self-correction), 생성 SQL 노출
KG	전체 로드 + 문자열 매칭	엔티티 임베딩 시드 + 엔티티 해소 + 타입 온톨로지 → 1홉 서브그래프
문서	md 6종	md + PDF + URL 혼합 (docling 변환)
오케스트레이션	파이썬 단일패스 라우터	Langflow 에이전트가 메인 (tool-calling, 파이썬은 폴백)

- 공통: 라우터에 관계형 키워드 백스톱 (granite의 graph 과소선택 보완)
- 원칙: 데모는 명료·안정 / 프로덕션 경로는 README "데모 ↔ 프로덕션" 표로 정직하게

고도화 ★ — text-to-SQL (watsonx.data)

corpus 인벤토리 고정쿼리 → 실제 비즈니스 데이터에 자연어 질의

- 데이터셋: iceberg_data.aml (AML/금융 테마) — customers · accounts · transactions · str_reports
- 파이프라인:

질문 → granite가 Presto SELECT 생성 (스키마카드 + few-shot)
→ 가드 (SELECT-only · 자동 LIMIT · DDL 차단)
→ 실행, 에러 시 self-correction 1회
→ 결과 + 생성 SQL 을 패널에 노출

- 예: "위험등급 high 고객의 플래그 거래 총액을 상대국가별로?" → 3-테이블 조인 SQL 자동 생성·실행
- 프로덕션 경로: 시맨틱 레이어/dbt · 행수준 보안 · 쿼리 검증

고도화 — Langflow로 오케스트레이션을 눈으로

watsonx granite Agent가 RAG 도구를 스스로 골라 호출하는 비주얼 플로우 — 챗 UI의 메인 오케스트레이터(파이썬 에이전트는 폴백)

```
ChatInput → Agent (IBM watsonx.ai) → ChatOutput
          ▲ tools
          search_documents(vector) · lookup_relationships(graph) · query_business_data(SQL)
```

- rag-ui가 도구를 HTTP 엔드포인트로 노출 (/api/tool/{vector,graph,sql} , 토큰 게이트)
- 챗 UI /api/chat → Langflow 실행 → 응답의 tool 출력으로 근거 패널(청크·KG·SQL) 그대로 복원
- 검증: "위험등급 high 고객 수?" → query_business_data → "7명" / 관계 질문 → KG 16엣지
- 대화별 session_id(브라우저 uuid)로 멀티턴 후속 질문 지원 + 사용자 격리 · "새 대화" 버튼으로 리셋 · Langflow 실패 시 파이썬 폴백
- 플로우 JSON·재생성 스크립트: integrations/genai/flows/

심화 ① — KG를 NoSQL(AstraDB)에 담은 스키마

왜 그래프DB가 아니라 NoSQL? 코퍼스가 작고(8문서 · ~100노드/108엣지), 질의는 "엔티티 주변 1홉 서브그래프"뿐 → 멀티홉 순회 엔진 불필요. 엔티티 임베딩으로 시드를 찾아 1홉 이웃만 읽으면 충분.

단일 컬렉션 **kg** — **kind** 필드로 노드/엣지 구분 (AstraDB Data API JSON 문서)

```
{ "_id": "<doc_id>:e:3", "kind": "entity", "doc_id": "...", "name": "마이데이터",  
  "type": "service_provider", "norm": "마이데이터", "emb": [...768d...] }  
  
{ "_id": "<doc_id>:r:5", "kind": "edge", "doc_id": "...",  
  "src": "마이데이터", "rel": "based_on", "dst": "신용정보법",  
  "src_norm": "마이데이터", "dst_norm": "신용정보법" } // 정규화 트리플
```

- **_id** = **doc_id** 스코프 → 문서별 delete→insert로 먹등 재적재 · **emb** = 768-d 임베딩(시드·해소용)
- ***_norm** = 정규화 키(별칭 병합) · **rel** = 통제 어휘 14종, **type** = 온톨로지 11종(snake_case 정규화)

심화 ② — KG 적재·질의 동작

적재 (write) — 문서 1건 → 같은 doc_id로 삭제 후 재삽입

```
granite가 {entities(type), edges} 추출 (타입 온톨로지 = 통제 어휘)
→ 엔티티 임베딩(emb) + 엔티티 해소(norm + 코사인 ≥ 0.90 병합)
→ astra_delete_all(doc_id) → insertMany # 먹등
```

질의 `tool_graph` (read) — 벡터 시드 + 1홉 이웃 조회

```
질문 임베딩 → 엔티티 emb 와 코사인 → 의미적 시드 엔티티 선정
→ 1홉 엣지 조회 find({kind:edge, $or:[src_normES, dst_normES]})
→ 점수 = 질문 언급(+2) + 시드(+1) → *_norm 병합 · 자기루프 제거 → 칩 + 트리플
```

- 엔티티 해소: 정규화 키 + 임베딩 코사인으로 별칭/표기 변형 병합 (그래프엔진 불필요)
- ⚠ 이 AstraDB는 서버사이드 벡터 ANN 미지원(SAI 'aa') → KG가 작아 코사인 앱-사이드 계산
- 트레이드오프: 1홉 한정(멀티홉 순회 X). 스케일·트래버설은 → CQL 파티션 / 그래프DB

품질 개선 — 적용 완료

- 하이브리드 검색 — 벡터(의미) + BM25(정확매칭) **RRF 융합**
→ 약어·법령명(STR · VASP · CISO)에 강함
- **cjk 분석기** — 한글을 bigram 토큰화 → 한글 BM25 recall 대폭 개선
(nori는 operator 관리 클러스터라 설치 불가 → 내장 cjk로 대체)
- **KG 정규화·해소** — 정규화 + 임베딩 코사인 엔티티 해소(별칭 병합) ·
타입 온톨로지(통제 어휘) · 관계 snake_case 강제 · 자기루프 제거
- **text-to-SQL 가드** — read-only(SELECT-only + LIMIT) · 실행 에러 self-correction 1회
- **라우터 백스톱** — 관계형 키워드로 graph 경로 보강 (granite 과소선택 보완)


배포 — 이미지 빌드 없이

- 내부 레지스트리 **Removed** 환경 → 이미지 빌드 불가
- 해법: **ConfigMap + 런타임 pip-install** 패턴
 - 코드/정적파일을 ConfigMap으로 마운트 → `ubi9/python-312` 가 기동 시 설치·실행
- 단일 컨테이너 FastAPI — 모든 자격증명은 백엔드(`rag-secrets`)에 보관
- 그래프 질의가 30s 초과 → 라우트 타임아웃 `120s` 설정

```
oc -n genai-apps create configmap rag-code --from-file=*.py --dry-run=client -o yaml | oc apply -f -
oc -n genai-apps rollout restart deploy/rag-ui # 이미지 빌드 없음
```


보안 — 공유 비밀번호 게이트

- 채팅 UI는 공유 비밀번호 로그인으로 보호 (서명된 세션 쿠키, HMAC)
- `rag-secrets` 의 `APP_PASSWORD` 키로 설정 — 키 없으면 인증 없이 열림 (하위호환)
- 미인증: 페이지 → `/login` 리다이렉트, API → `401`
- ⚠ 적재/삭제는 로그인 후 누구나 가능(데모 목적)
→ 운영엔 사용자별 인증 + 트랜잭션 보강 필요



알아둘 한계 (데모 수용 범위)

- 무인증 쓰기 — 적재/삭제 공개. 운영 시 인증·outbox 트랜잭션 필요
- 라우터 비결정성 — granite가 graph 과소선택 → 키워드 백스톱으로 보강(완전 결정적은 아님)
- 그래프 순회 아님 — 1홉 서브그래프 수준(멀티홉 X). AstraDB 비벡터 NoSQL → 벡터 시드는 앱-사이드 코사인
- **text-to-SQL** 범위 — read-only 가드; 복잡 조인은 few-shot로 유도(완전 일반화 X)
- **docling-graph** 미사용 — KG는 granite LLM 추출. docling-graph는 스캔PDF/복잡표용 옵션

핵심 메시지

- **Agentic RAG** = 검색 하나가 아니라, 질문에 맞는 도구를 고르는 것
- **Explainability** = 답뿐 아니라 근거를 보여줘야 신뢰가 생긴다
- **AI-Ready Context** = 같은 문서를 벡터·그래프·**SQL** 세 형태로 준비
- **watsonx + OpenShift** = 규제 산업에서도 거버넌스 가능한 스택

데모: `https://rag-ui-genai-apps.apps.<CLUSTER_DOMAIN>`

코드: `github.com/kiyeonjeon21/techxchange-ai-ready-context`

Q&A / 부록 — 기술 노트

- watsonx.data Presto는 **PrestoDB** (`presto-python-client` , trino 아님)
- OpenSearch: faiss 없음 → **lucene kNN**, 한글 BM25는 **cjk** 분석기
- KG: granite 추출 + 임베딩(`emb`) 엔티티 해소 + 타입 온톨로지; 1홉은 `$or/$in` 서버 필터
- text-to-SQL: 스키마카드+few-shot, SELECT-only 가드, self-correction
(`iceberg_data.sql`)
- 모델: granite (챗 엔진 라우팅/합성/text2sql) + granite-embedding-278m-multilingual (768d)
 - Langflow 플로우는 watsonx 컴포넌트 모델목록 제약으로 **granite-4-h-small** 사용
- Langflow: 챗 UI `/api/chat` 의 메인 오케스트레이터(파이썬 폴백) → rag-ui `/api/tool/*` (토큰 게이트) tool-calling (`flows/agent-rag.json`)
- 파싱: docling-serve `/v1/convert/source` (URL) · `/v1/convert/file` (multipart, PDF)